





Estadística multivariada

Por Tomás Olarte y Santiago Hernández



02 Supervisado básico

Hola!



Soy Tomás Olarte

tolarteh@eafit.edu.co

Ingeniero matemático y estudié inteligencia artificial en mi maestría porque me encanta que las máquinas trabajen por mí en las tareas repetitivas.



Prof. Diego Kuonen @DiegoKu...

"AI is not about replacing the human with a robot. It is about taking the robot out of the human."

Hoy aprenderemos...



Aprendizaje supervisado

- Notación para el aprendizaje supervisado
- Conocer el problema de regresión
- Solucionar la regresión lineal
- Extender a la regresión NO lineal
- [TAREA] Implementar una regresión lineal.

Conceptos básicos

Inteligencia artificial

- Sistemas lógicos
- Sistemas expertos
- Algoritmos genéticos

Aprendizaje automático

- Árboles de decisión
- PCA
- SVM

Aprendizaje profundo

La **inteligencia artificial (AI)** estudia la simulación de comportamientos inteligentes.

El **machine learning (ML)** estudia los algoritmos que mejoran su rendimiento incorporando nuevos datos a un modelo existente.

El **deep learning** usa algoritmos de redes neuronales artificiales para extraer características cada vez más complejas a partir de los datos de entrada, buscando imitar al cerebro.

ML Supervisado

$$D = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\} \subseteq \mathcal{R}^d \times \mathcal{C}$$

D es el conjunto de datos

\mathcal{R}^d es el espacio de atributos d -dimensional

\mathbf{x}_i es el vector de entrada del ejemplo i

y_i es la etiqueta del ejemplo i

\mathcal{C} es el espacio de etiquetas


Regresión	$\mathcal{C} = \mathbb{R}$	Ej. Predecir la altura futura de una persona
Clasificación binaria	$\mathcal{C} = \{0, 1\}$ $\mathcal{C} = \{-1, +1\}$	Ej. Realizar un filtro de correo spam
Clasificación multi-clase	$\mathcal{C} = \{1, 2, \dots, K\}$	Ej. Clasificar la cara de una persona donde se tienen K identidades (Obama, Bush, etc.)

Regresión

Quiero encontrar una relación

$$y = f(x)$$

donde **y** es una variable continua.



Regresión lineal

$$y = \beta X + \varepsilon$$


Statistics

2009

$$y = \beta X + \varepsilon$$


**MACHINE
LEARNING**

2019



Regresión lineal

- Ajustar una **línea** a las observaciones
- Usar esta línea para **predecir** valores no observados
- Usualmente se encuentra con el método de los **mínimos cuadrados**
- Si la relación no es lineal, se puede **procesar las entradas** para reflejar esta relación.



Regresión lineal

Supuesto del modelo: una relación lineal


$$y = f(\mathbf{x}) = w_0 + \sum_{j=1}^d w_j \times x_j$$

Al predecir:

$$\hat{y} = \hat{f}(\mathbf{x}) = w_0 + \sum_{j=1}^d w_j \times x_j$$

$$\hat{y} = \hat{f}(\mathbf{x}) = \mathbf{x}^T \mathbf{w}$$

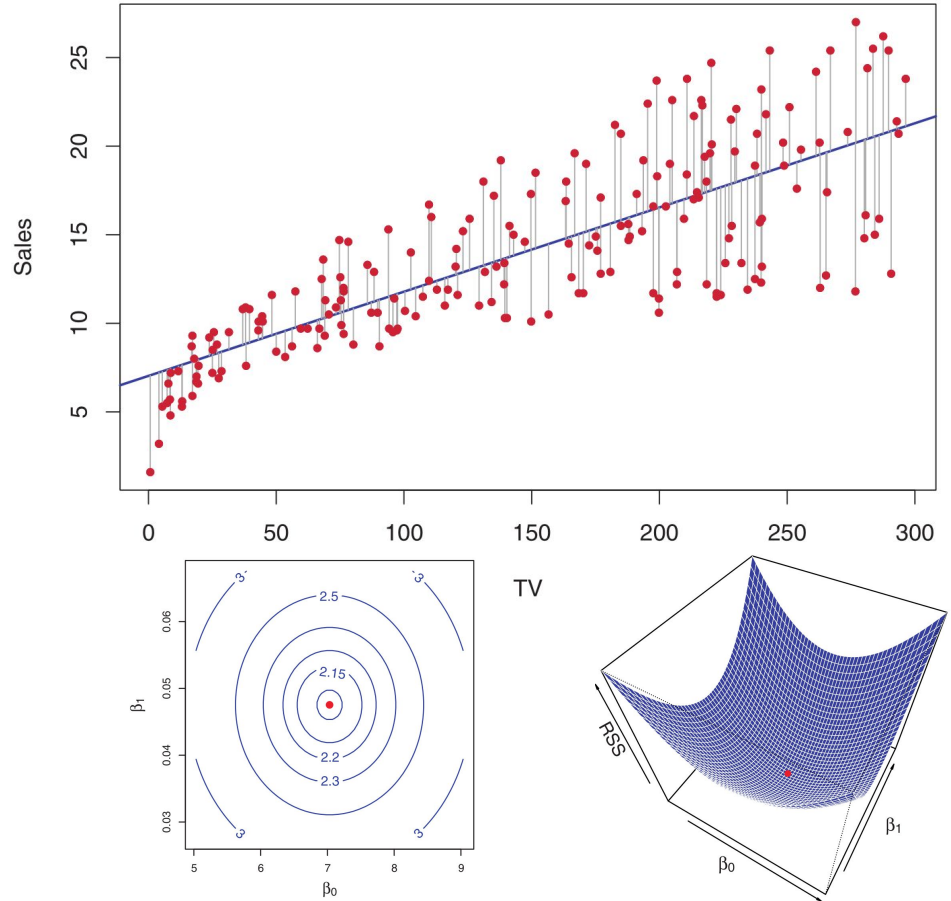
Representación alternativa



Mínimos cuadrados

Minimiza el error de ajuste de la línea a cada punto (en realidad el error promedio):

- No me interesa si se equivoca por encima o por debajo (**error al cuadrado** o error absoluto)
- **Sumo** los errores entre todos los puntos (suma de errores cuadrados)
- Encuentro el **óptimo** valor de dicha suma, esto lo puedo hacer de manera analítica (*ecuación normal*) o iterativa (*descenso por el gradiente*).



Mínimos cuadrados

$$\begin{array}{ll} y_1 & \mathbf{x}_1 \\ y_2 & \mathbf{x}_2 \\ \vdots & \vdots \\ y_n & \mathbf{x}_i \\ \vdots & \vdots \\ y_i & \mathbf{x}_n \end{array} \qquad \begin{array}{l} \hat{y}_1 = \hat{f}(\mathbf{x}_1) = \mathbf{x}_1^T \mathbf{w} \\ \hat{y}_2 = \hat{f}(\mathbf{x}_2) = \mathbf{x}_2^T \mathbf{w} \\ \vdots \\ \hat{y}_i = \hat{f}(\mathbf{x}_i) = \mathbf{x}_i^T \mathbf{w} \\ \vdots \\ \hat{y}_n = \hat{f}(\mathbf{x}_n) = \mathbf{x}_n^T \mathbf{w} \end{array}$$

Debemos encontrar \mathbf{w} que haga mínima la diferencia entre el valor real y la predicción:

$$\mathbf{w} = \arg \min_{\mathbf{w}} \sum_{i=1}^n (y_i - \mathbf{x}_i^T \mathbf{w})^2$$

Mínimos cuadrados

Teniendo esta función objetivo:

$$\begin{aligned}\mathbf{w} &= \arg \min_{\mathbf{w}} \sum_{i=1}^n (y_i - \mathbf{x}_i^T \mathbf{w})^2 \\ &= \arg \min_{\mathbf{w}} (Y - \mathbf{X}\mathbf{w})^T (Y - \mathbf{X}\mathbf{w})\end{aligned}$$

Podemos encontrar una solución analítica (ecuación normal):

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} (\mathbf{X}^T Y)$$


Métricas

Diferentes métricas para los problemas de regresión pueden ser usadas, pero entre las más usadas están:

- MSE
- R2

Name	Formula	sklearn
Mean squared error	$\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$	mean_squared_error
Mean squared log error	$\frac{1}{N} \sum_{i=1}^N (\ln(1 + y_i) - \ln(1 + \hat{y}_i))^2$	mean_squared_log_error
Mean absolute error	$\frac{1}{N} \sum_{i=1}^N y_i - \hat{y}_i $	mean_absolute_error
Median absolute error	$\text{median}(y_1 - \hat{y}_1 , \dots, y_n - \hat{y}_n)$	median_absolute_error
Explained variance	$1 - \frac{\text{var}(y - \hat{y})}{\text{var}(y)}$	explained_variance_score
R2 score	$1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}$	r2_score

Métricas



Al usar las diferentes métricas, resultados ligeramente diferentes pueden ocurrir, pero **los supuestos** del modelo deben mantenerse para considerar el modelo adecuado.

Regresión no lineal

Una **regresión no lineal** supone que la relación entre la variable dependiente y las independientes es una combinación lineal de transformaciones no lineales de las variables predictores.

$$\hat{y}_i = \hat{f}(\mathbf{x}_i) = \mathbf{x}_i^T \mathbf{w} \longrightarrow \hat{y}_i = \hat{f}(\phi(\mathbf{x}_i)) = \phi(\mathbf{x}_i)^T \mathbf{w}$$

ϕ :


- Cualquier función que haga una transformación no lineal sobre las variables de entrada al modelo.

Ejemplo:

$$\langle x_1, x_2 \rangle \longrightarrow \langle x_1^2, \sin x_2, x_1 x_2 \rangle$$


Regresión no lineal

[sklearn.preprocessing.PolynomialFeatures – scikit-learn 0.22.1 documentation](#)



A mayor complejidad del modelo, más capacidad de “memorizar” los datos de entrenamiento, llevando al modelo a generalizar en menor grado (pobres resultados en pruebas): **sobreajuste**.

Básico: Sesgo vs. Varianza

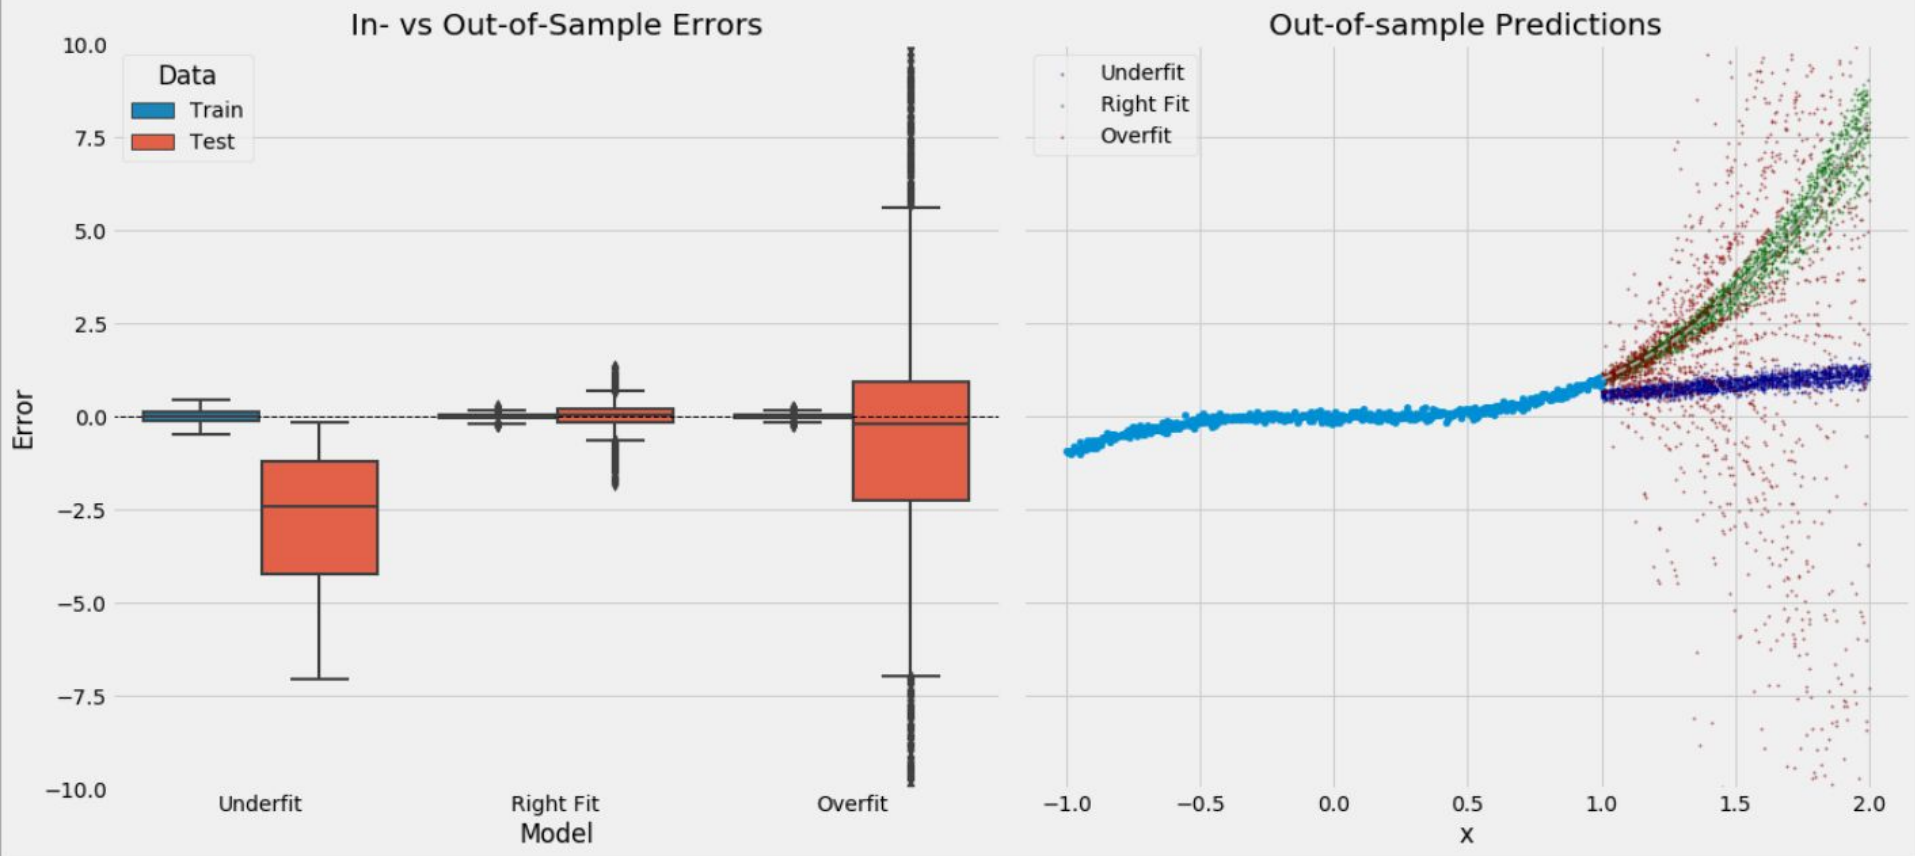


Generalmente en el proceso de modelación se debe sopesar el **sesgo** del modelo respecto a la realidad y su **varianza** en nuevas muestras.

Para **disminuir** esta varianza se recomienda:

1. Simplificar el modelo
 - a. Quitar variables
 - b. Cambiar hiper-parámetros
 - c. Cambiar el tipo de modelo
2. Más datos de entrenamiento
3. Regularización en el modelo.

Bias - Variance Tradeoff: Under vs. Overfitting



Un poco de práctica

Programar la solución analítica de regresión lineal

<http://bit.ly/eafit-reglineal>